

05. Ba kiến trúc Deep Learning

ResNet18, DenseNet121, ViT-B/16 - áp dụng cho bài toán phân loại 88 loại hạt giống

1. ResNet18 - "Đường tắt" giải quyết Vanishing Gradient

Vấn đề trước ResNet (2015)

Trực giác cũ: mạng càng sâu càng học được nhiều đặc trưng phức tạp hơn. Nhưng thực nghiệm cho thấy mạng 56 tầng lại có error rate cao hơn mạng 20 tầng - không phải do overfitting, mà do vanishing gradient: khi lan truyền ngược qua quá nhiều tầng, gradient bị nhân dồn nhiều lần với số nhỏ hơn 1 -> tiến gần 0 -> các tầng đầu gần như không học được gì.

Ý tưởng cốt lõi: Residual Connection (skip connection)

Thay vì bắt một khối layer học trực tiếp hàm mục tiêu $H(x)$, ResNet cho nó học phần dư (residual):

$$F(x) = H(x) - x \Rightarrow H(x) = F(x) + x$$

Input x -----+-----> (+) -> Output
 |
 +--> Conv-BN-ReLU-Conv-BN -+
 (day là $F(x)$, phần cần học)

Tại sao điều này giải quyết vanishing gradient? Vì có đường "tắt" (identity path) cộng thẳng x vào output, khi đạo hàm ngược qua khối này, gradient luôn có ít nhất đường +1 (đạo hàm của phép cộng) để truyền về, không bị triệt tiêu hoàn toàn dù $F(x)$ có gradient rất nhỏ.

Cấu trúc cụ thể ResNet18

Tầng	Thành phần	Kích thước output
Input	Ảnh RGB	224x224x3
Conv1	7x7, stride 2	112x112x64
MaxPool	3x3, stride 2	56x56x64
Layer1	2 residual block, 64 filters	56x56x64
Layer2	2 residual block, 128 filters	28x28x128
Layer3	2 residual block, 256 filters	14x14x256
Layer4	2 residual block, 512 filters	7x7x512
GAP + FC	Global Avg Pool -> Linear(512, 88)	88 (số lớp hạt giống)


Tổng: 18 tầng có trọng số (tên gọi "18" từ đây) - 2+2+2+2 blocks x 2 conv layers/block + conv1 + fc = 18. Tham số: ~11.7 triệu.

2. DenseNet121 - Kết nối TẤT CẢ với TẤT CẢ

Ý tưởng cốt lõi: Dense Connectivity

ResNet cộng output của layer trước vào layer sau (chỉ 1 kết nối tắt). DenseNet đi xa hơn: mỗi layer trong một "Dense Block" nhận input là nối (concatenate) của TẤT CẢ layer trước đó, không phải chỉ layer liền kề:

$$x_l = H_l([x_0, x_1, x_2, \dots, x_{(l-1)}])$$



Khác biệt quan trọng với ResNet: ResNet dùng phép cộng (+) -> giữ nguyên số kênh (channels). DenseNet dùng phép nối (concatenate) -> số kênh tăng dần qua mỗi layer.

Growth rate (k)

Mỗi layer trong Dense Block chỉ tạo ra thêm $k=32$ feature map mới (gọi là growth rate), rồi nối vào "kho chung". Vì layer sau nhận được toàn bộ đặc trưng của mọi layer trước, mỗi layer không cần học lại đặc trưng đã có - đây gọi là feature reuse, giúp DenseNet ít tham số hơn ResNet dù sâu hơn (121 tầng nhưng chỉ ~8 triệu tham số, so với 11.7 triệu của ResNet18 dù ít tầng hơn).

Cấu trúc cụ thể DenseNet121

Thành phần	Số layer	Vai trò
Dense Block 1	6 layer	Học đặc trưng, số kênh tăng dần
Transition 1	1x1 conv + pooling	Giảm số kênh & kích thước không gian
Dense Block 2	12 layer	—
Transition 2	1x1 conv + pooling	—
Dense Block 3	24 layer	—
Transition 3	1x1 conv + pooling	—
Dense Block 4	16 layer	—
GAP + FC	—	Linear(1024, 88)

Tổng tầng có trọng số ≈ 121 (tên gọi "121"). Tham số: ~8 triệu - ít hơn ResNet18 dù sâu hơn nhiều.

Transition layer (1x1 conv) là bắt buộc: vì concatenate liên tục làm số kênh phình to rất nhanh, transition dùng conv 1x1 để "nén" số kênh lại trước khi vào block tiếp theo.

3. ViT-B/16 - Ảnh không còn là ảnh, mà là... câu văn

Vấn đề: CNN vs Transformer

ResNet và DenseNet đều là CNN (Convolutional Neural Network) - dùng phép tích chập để bắt đặc trưng cục bộ (local), rồi tầng sau mới dần dần "nhìn thấy" vùng rộng hơn. Vision Transformer (ViT) lấy ý tưởng từ Transformer trong NLP và áp dụng thẳng vào ảnh, bỏ hẳn convolution.

Ý tưởng cốt lõi: Ảnh = Chuỗi các "từ" (patch)

```
Anh 224x224x3
|
v Chia thành các patch 16x16 (không chồng lấn)
+---+---+---+---+
| 1 | 2 | 3 | ... | -> 14x14 = 196 patches
+---+---+---+---+
|
v Mỗi patch làm phẳng (16x16x3=768 số) -> Linear projection
[CLS] [patch1] [patch2] ... [patch196] <- giống một "câu" 197 từ
|
v + Positional Embedding (vì Transformer không có khái niệm thứ tự)
|
v Qua N=12 tầng Transformer Encoder (Self-Attention + MLP)
|
v Lay vector [CLS] ở output -> Linear(768, 88)
```

Tên gọi "B/16": "B" = Base (kích thước trung bình so với Small/Large/Huge), "16" = kích thước mỗi patch là 16x16 pixel.

Self-Attention - trái tim của Transformer

Mỗi patch "nhìn" vào tất cả các patch khác (kể cả chính nó) và tính trọng số chú ý (attention weight) xem patch nào liên quan nhất đến mình:

$$Attention(Q, K, V) = softmax(Q \cdot K^T / \sqrt{d_k}) \cdot V$$

Khác biệt cốt lõi so với CNN: một conv layer chỉ nhìn được vùng nhỏ xung quanh (VD 3x3), phải qua nhiều tầng mới "nhìn" được toàn ảnh. Self-attention ngay từ tầng đầu tiên đã cho phép patch ở góc trái nhìn thấy patch ở góc phải - gọi là global receptive field ngay từ đầu.

Cấu trúc cụ thể ViT-B/16

Thành phần	Giá trị
Patch size	16x16
Số patch (ảnh 224x224)	196 (+1 token [CLS])
Hidden dimension	768
Số tầng Encoder	12
Số attention head / tầng	12
Tham số	~86 triệu

Điểm yếu quan trọng: ViT cần NHIỀU dữ liệu

CNN có sẵn *inductive bias* (giả định trước): tính cục bộ (*locality*) và bất biến dịch chuyển (*translation invariance*) được "khắc cứng" vào kiến trúc *convolution*. ViT không có giả định này - nó phải tự học những quy luật đó từ dữ liệu, nên cần *dataset* rất lớn (ViT gốc train trên JFT-300M, 300 triệu ảnh) mới vượt được CNN. Với *dataset* nhỏ, ViT thường kém hơn CNN nếu train *from scratch*.

4. Liên hệ trực tiếp với dự án seed-classification

Với *dataset* của anh (quy mô tương tự LZUPSD: ~4496 ảnh, 88 lớp - trung bình chỉ ~51 ảnh/lớp), đây là điểm cần lưu ý:

Mô hình	Tham số	Rủi ro với dataset nhỏ (~4496 ảnh / 88 lớp)
ResNet18	~11.7M	Thấp - inductive bias mạnh, phù hợp fine-tune
DenseNet121	~8M	Thấp - ít tham số nhất, feature reuse hiệu quả với ít data
ViT-B/16	~86M	Cao - nếu train from scratch với 4496 ảnh sẽ overfit nặng

=> Với ViT-B/16, anh gần như bắt buộc phải dùng **transfer learning** (tải trọng số pretrained trên ImageNet, chỉ fine-tune phần cuối hoặc toàn bộ với learning rate rất nhỏ), chứ không nên train từ đầu.

5. Bảng từ vựng

Từ	Phiên âm	Nghĩa
Residual connection	/rɪˈzɪdʒəl kəˈnekʃən/	Kết nối dư (skip connection)
Vanishing gradient	/ˈvænɪʃɪŋ ˈɡreɪdɪənt/	Đạo hàm biến mất dần qua các tầng
Dense connectivity	/dens ˌkɒnekˈtɪvəti/	Kết nối dày đặc (mọi layer nối mọi layer)
Growth rate	/grəʊθ reɪt/	Tốc độ tăng trưởng kênh (feature map) mỗi layer
Feature reuse	/ˈfi:tʃə riːˈjuːz/	Tái sử dụng đặc trưng đã học
Transition layer	/trænˈzɪʃən ˈleɪə/	Tầng chuyển tiếp (nén số kênh)
Patch embedding	/pætʃ ɪmˈbedɪŋ/	Nhúng mảnh ảnh nhỏ thành vector
Positional embedding	/pəˈzɪʃənəl ɪmˈbedɪŋ/	Nhúng thông tin vị trí
Self-attention	/self əˈtenʃən/	Cơ chế tự chú ý giữa các phần tử
Receptive field	/rɪˈseptɪv fiːld/	Vùng ảnh mà một điểm đặc trưng "nhìn thấy"
Inductive bias	/ɪnˈdʌktɪv ˈbaɪəs/	Giả định cấu trúc được khắc sẵn vào mô hình
Transfer learning	/ˈtrænsfɜː ˈlɜːnɪŋ/	Học chuyển giao (dùng trọng số pretrained)

6. Tóm tắt / Kết luận

- ResNet18: giải quyết vanishing gradient bằng residual connection (phép cộng $x + F(x)$), 18 tầng, ~11.7M tham số

- DenseNet121: kết nối dày đặc bằng concatenate, feature reuse giúp giảm tham số dù sâu hơn (121 tầng, ~8M tham số)
- ViT-B/16: chia ảnh thành 196 patch, xử lý như một chuỗi bằng self-attention, có global receptive field ngay từ đầu nhưng cần nhiều dữ liệu (~86M tham số)
- Với dataset nhỏ (~4496 ảnh / 88 lớp) như seed-classification, ResNet18 và DenseNet121 an toàn hơn để train from scratch; ViT-B/16 nên dùng transfer learning